Progetto-I
Analisi predittiva del dataset Yelp: Dalla Regressione Lineare alla classificazione SVM

1. Obiettivi

Nel moderno ecosistema digitale, le piattaforme digitali come **Yelp** rappresentano un ponte critico tra le aziende e i consumatori. Mentre il numero di “stelle” (rating) è l’indicatore principale della qualità di un servizio, le varie interazioni della community (che vengono espresse tramite feedback **Cool, Useful** e **Funny**) aggiungono una dimensione sociale al dato.
Il progetto si pone l’obiettivo di determinare se esiste un legame matematico solido tra le interazioni social e il rating assegnato. Nello specifico ci chiediamo se è possibile prevedere il numero di stelle di una recensione analizzando quanto essa sia stata apprezzata dagli altri utenti.
Il progetto segue la seguente pipeline:

- Esplorazione e analisi dei dati: identificazione di bias, outlier e correlazioni;
- Modellazione regressiva: tentativo di predire il valore continuo di stelle e ottimizzazioni tramite **feature selection**;
- Modellazione classificativa: trasformazione del problema in un task di classificazione multiclasse utilizzando la **Support Vector Machine (SVM)**;

Il dataset utilizzato è il yelp.csv, che contiene migliaia di record, ognuno dei quali rappresenta una singola recensione scritta da un utente per un’attività commerciale locale.
Le variabili chiave analizzate sono:

- Stars (Target): una variabile numerica (da 1 a 5) che rappresenta il punteggio finale;
- Useful (Feature): indica il numero di persone che hanno trovato la recensione utile;
- Cool (Feature): indica il numero di persone che hanno trovato la recensione interessante;
- Funny (Feature): indica il numero di persone che hanno trovato la recensione divertente;

Per lo sviluppo del progetto è stato utilizzato il linguaggio di programmazione Python. Le librerie principali includono:

- Pandas: per la manipolazione e l’analisi tabellare dei dati;
- Seaborn e Matplotlib: per la generazione di grafici statistici e la visualizzazione delle relazioni;
- Scikit-learn: per l’implementazione di algoritmi di Machine Learning - nel nostro caso Regressione Lineare e SVM - e per le metriche di valutazione;
  Il primo passo consiste nell’importazione dei dati e nella verifica della loro integrità. Utilizzando df.info() e df.describe() si è osservato che:

- Il dataset presenta una struttura pulita con assenza di valori nulli nelle colonne target. Questo è un passaggio molto importante, perché la presenza di dati mancanti avrebbe richiesto tecniche di imputazione che avrebbero potuto distorcere la distribuzione originale;
- Le variabili cool, useful e funny hanno una deviazione standard molto superiore alla loro media.

2. Analisi esplorativa dei dati

Il primo passaggio dell'analisi è stato visualizzare la frequenza dei rating tramite un grafico **Countplot.**
Dall'osservazione del grafico, il dataset non presenta una distribuzione uniforme evidenziando uno sbilanciamento delle classi, in quanto si è rilevata una netta prevalenza di recensioni con 4 e 5 stelle rispetto a quelle con 1 o 2 stelle. Questo fenomeno è noto come Bias di Positività delle piattaforme social: gli utenti tendono a recensire con più frequenza le esperienze che hanno soddisfatto o superato le loro aspettative, oppure i casi estremamente negativi, lasciando poco spazio alle valutazioni mediane o moderatamente basse.
Data la struttura sbilanciata è possibile utilizzare delle tecniche di data resampling, come:

- Oversampling: consiste nell'aumentare il numero di istanze delle classi minoritarie;
- Undersampling: consiste nel rimuovere casualmente un numero di istanze maggioritarie per pareggiarle a quelle meno rappresentate, presentando tuttavia il rischio di perdere informazioni ritenute importanti;

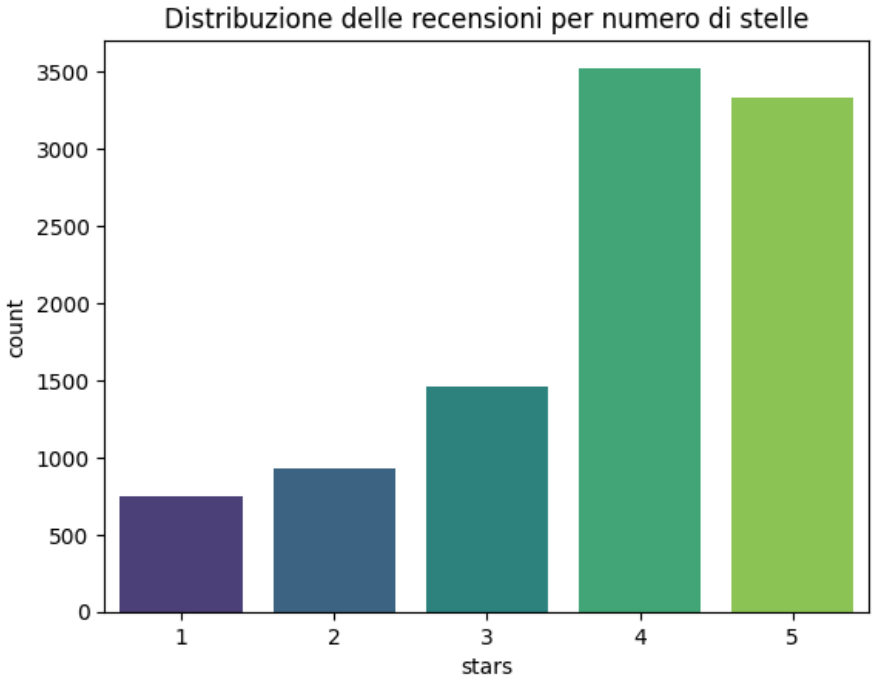

Per visualizzare la forza e la direzione dei legami tra le variabili del dataset, è stata generata una matrice di correlazione tramite **Heatmap**. Questo strumento è

fondamentale per identificare quali caratteristiche abbiano un reale potere predittivo nei confronti del target.

Dall'osservazione dei coefficienti relativi alla riga Stars emerge che i valori sono estremamente prossimi allo zero; ciò comporta un'assenza di relazione lineare tra il rating assegnato (Stars) e il feedback ricevuto dalla community. In pratica, l'apprezzamento social di una recensione non è un indicatore affidabile della sua popolarità, in quanto una recensione estremamente negativa può essere considerata "utile" o "divertente" tanto quanto una positiva.

Un altro aspetto importante emerge osservando la relazione tra le sole variabili indipendenti. Infatti, si è notata una correlazione molto elevata tra i tre tipi di feedback. In fase di modellazione, la presenza di questo fenomeno può causare instabilità nel calcolo dei coefficienti di regressione.

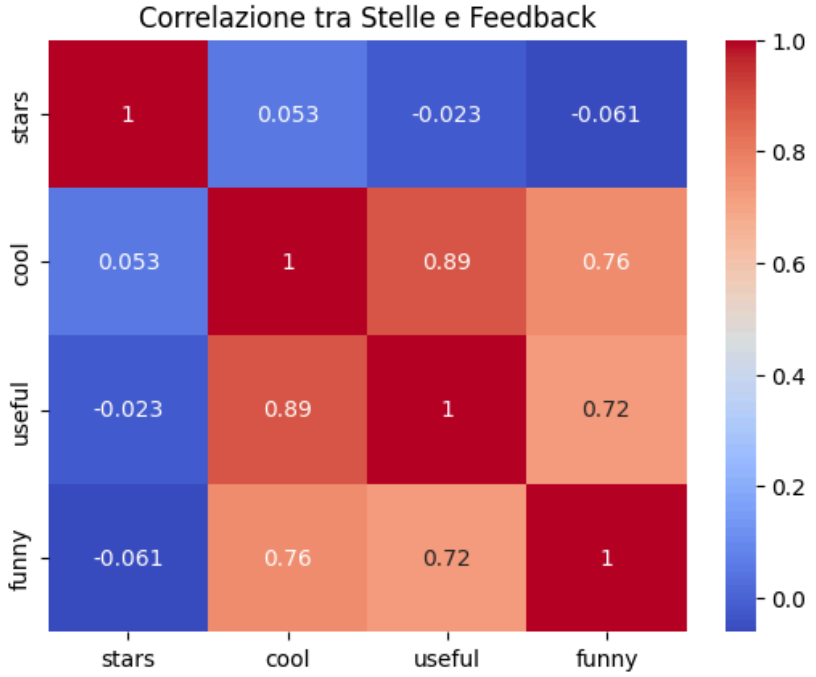

L'utilizzo dei Boxplot ha permesso di esaminare la distribuzione delle tre variabili indipendenti, rilevando caratteristiche strutturate del dataset che influenzeranno direttamente la fase di modellazione. Dallo studio è emersa una struttura comune a tutte le feature social, ovvero la presenza di outlier.
La "scatola" è estremamente schiacciata verso l'asse delle ascisse. Questo significa che la maggioranza delle recensioni riceve pochissimi voti (0 o 1).

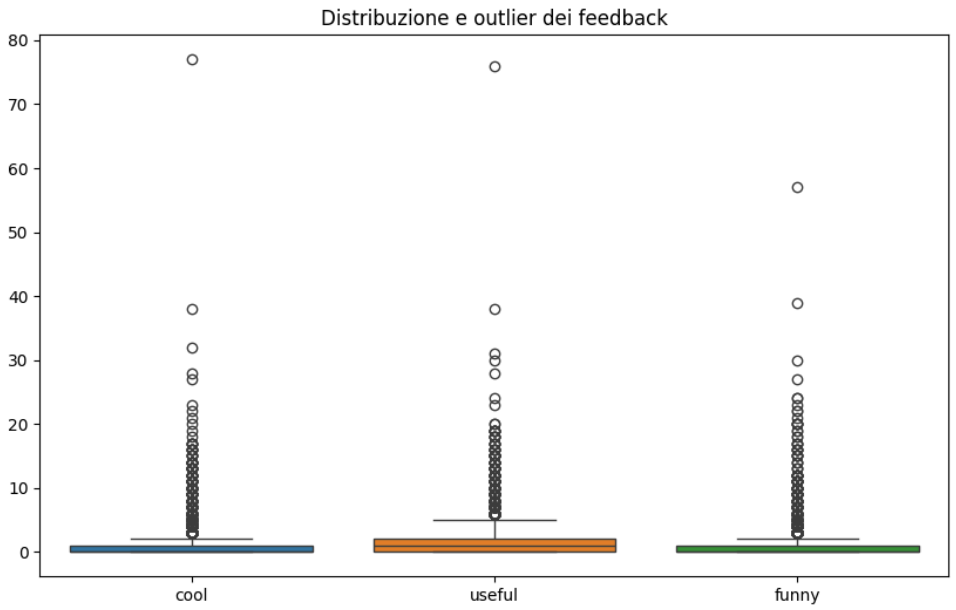

3. Modellazione tramite Regressione Lineare

In questa fase, l'obiettivo è stato quello di costruire un modello matematico capace di stimare il numero di stelle partendo dai feedback ricevuti. La sfida, come evidenziato dalla EDA, è data dalla scarsa correlazione e dalla presenza di outlier.
Il dataset è stato suddiviso in due sottoinsiemi indipendenti:

- Training Set (80%): utilizzato per permettere all'algoritmo di apprendere i coefficienti della retta di regressione;
- Test Set (20%): utilizzato per valutare la capacità di generalizzazione del modello su dati mai visti in precedenza;

L'adozione del parametro **random_state=1** garantisce la riproducibilità dell'esperimento, assicurando che le fluttuazioni nei risultati siano imputabili alle variazioni delle feature e non alla selezione casuale dei campioni.
Per misurare l'errore del modello, si è scelto di utilizzare la metrica RMSE (Root Mean Squared Error). Questa scelta è giustificata da due fattori critici:

- Omogeneità dimensionale: l'errore è espresso nella stessa unità di misura del target, facilitandone l'interpretazione;
- Sensibilità ai valori anomali (outlier): elevando gli scarti al quadrato, l'RMSE penalizza in modo quadratico gli errori di grandi dimensioni. Dato l'elevato numero di outlier rilevati nel boxplot, questa metrica fornisce una misura realistica dell'impatto del "rumore" statistico sul modello;

Dopo aver valutato il modello nella sua configurazione completa, è stata effettuata un'analisi granulare tramite una procedura di **Feature Selection** manuale.
Quest'analisi ha lo scopo di identificare se alcune variabili introducono "rumore" statistico anziché informazioni utili, peggiorando la capacità predittiva globale.
Il modello è stato addestrato e testato quattro volte, variando il set in input ma mantenendo lo split dei dati (80/20).

I test prodotti hanno prodotto i seguenti valori RMSE:

- L'RMSE del set completo è pari a 1.1837. Considerando che la scala delle stelle va da 1 a 5, abbiamo un errore di circa 1.2. Questo significa che i soli feedback sono predittori insufficienti per determinare con precisione il rating;
- Notiamo che passando dal set completo a una singola feature, l'RMSE aumenta il suo valore; ciò dimostra che le tre variabili sono fortemente ridondanti. Questo è riflesso pratico della multicollinearità che è stata individuata nella Heatmap e dimostra che aggiungere "useful" e "funny" al modello, già contenente "cool", non comporta quasi alcun beneficio informativo.

Il mancato miglioramento drastico indica una condizione di **High Bias (Underfitting)**. Le ragioni sono semplici:

- **Semplicità del modello**: la regressione lineare non è in grado di catturare relazioni non lineari complesse tra l'engagement social e il rating;
- **Assenza di dati semantici**: il feedback è un segnale indiretto; la reale determinante del voto è contenuta nel testo della recensione, qui non analizzato;
- **Outlier di leva**: i valori estremi identificati nei feedback agiscono come punti di leva, distorcendo la pendenza della retta e aumentando l'errore globale;

4. Modellazione tramite classificazione: Support Vector Machine (SVM)

Successivamente, il problema è stato riformulato come un compito di **classificazione multiclasse**. L'obiettivo non è più quello di stimare il valore numero, ma assegnare correttamente ogni recensione a una delle cinque categorie di rating (1 a 5).

Le SVM calcolano la distanza tra i punti per identificare l'iperpiano di separazione ottimale. Se le feature hanno scalare diverse, quella con i valori più alti dominerebbe il calcolo della distanza, rendendo il modello inefficiente.
Di conseguenza, prima dell'addestramento del modello SVM è stato necessario applicare una fase di Feature Scaling tramite lo Standard Scaler. Ogni feature è stata trasformata per avere una media pari a 0 e una deviazione standard pari a 1. Ciò garantisce che "cool", "useful" e "funny" contribuiscano equamente alla definizione dei confini di decisione.

Per la classificazione si è usato il modello SVC (Support Vector Classification) con i parametri di default. Il modello cerca di massimizzare il "margine" tra le classi, ovvero la distanza tra i punti più vicini di categorie diverse.

Di default, SVC utilizza il kernel **Radial Basis Function (RBF)**, che permette di creare confini di separazione non lineari, potenzialmente superando il problema del **High Bias** riscontrato nella regressione lineare.
Il modello ha restituito un'**accuratezza** del 35,25. A prima vista, questo valore potrebbe apparire insoddisfacente. Tuttavia, in un contesto di classificazione multiclasse, questa metrica deve essere ben analizzata. Nonostante la standardizzazione, il modello si scontra con il forte sbilanciamento delle classi (**Bias di Positività**). Con un'accuratezza così, è probabile che l'SVM riesca a identificare correttamente le recensioni da 4 e 5 stelle, ma fallisce quasi completamente nel caso delle classi minoritarie come le 1 o 2 stelle.

Per una maggiore visualizzazione dell'evento si è scelto di creare una **confusion matrix** usando una Heatmap. La matrice rivela in modo inequivocabile il comportamento del modello SVM davanti allo sbilanciamento delle classi.
L'osservazione più rilevante è la colonna relativa alla classe "**Predetti 4**", in cui si nota una massiccia concentrazione di previsioni, indipendentemente dal valore reale. Il modello ha classificato **683 recensioni da 4 stelle**, tuttavia, ha erroneamente classificato come 4 stelle la stragrande maggioranza delle altre classi.

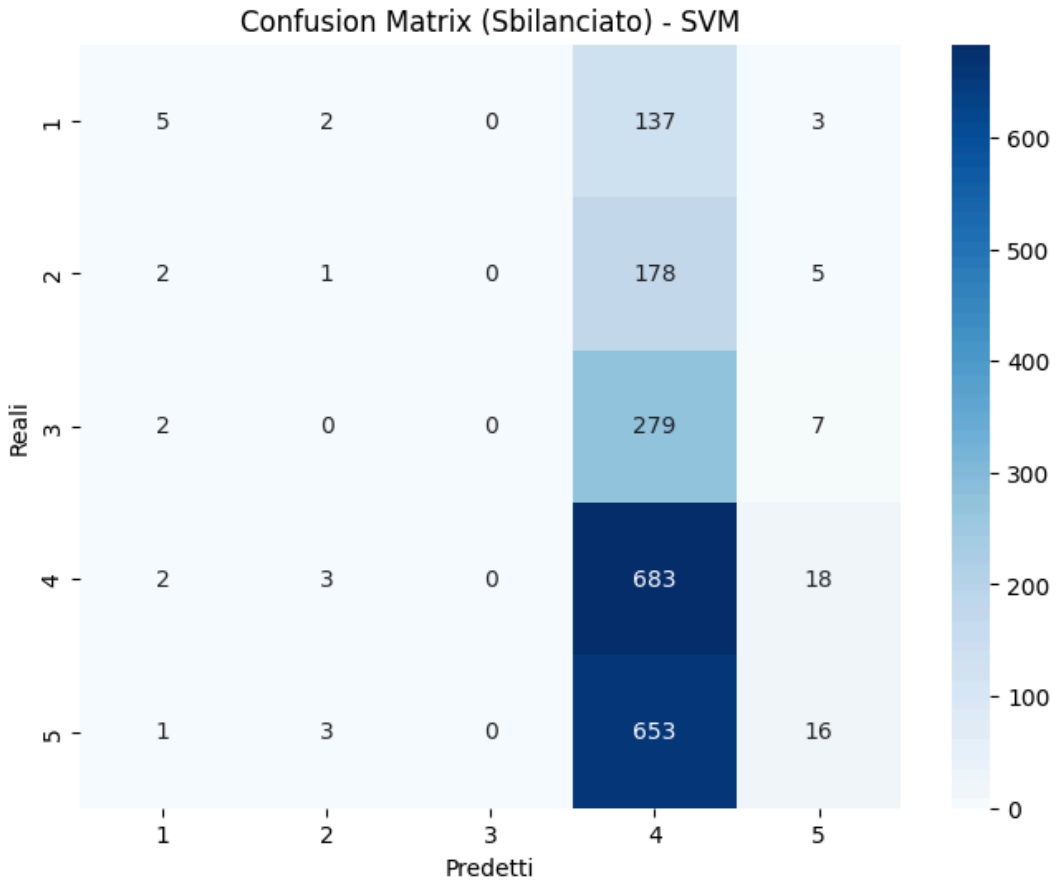

Questo fenomeno è la prova del **Bias Algoritmico** causato dalla distribuzione sbilanciata vista nel countplot. Il modello non sta realmente distinguendo i feedback ma sta semplicemente scommettendo sulla classe più probabile.

Per correggere il bias emerso dalla confusion matrix precedente, è stata implementata una variante del modello attraverso l'attributo **class_weight='balanced',** l'algoritmo SVC modifica la propria funzione di costo durante la fase di addestramento.

Invece di trattare ogni errore allo stesso modo, il modello assegna un "peso" maggiore agli errori commessi sulle classi meno rappresentate. Questo costringe a prestare più attenzione ai vettori di supporto delle classi minoritarie, evitando che vengano "schiacciati" dalla massa critica delle recensioni.

Con l'utilizzo di tale parametro, si è riscontrata un'accuratezza del 27.45%. Sebbene numericamente inferiore al precedente, questo valore rappresenta un modello statisticamente più onesto e utile. Questo calo indica la rimozione del bias di frequenza. Penalizzando gli errori sulle classi minoritarie, il modello è ora costretto a cercare confini di separazione anche per i voti bassi. Tutto ciò riduce l'accuratezza globale ma migliora la capacità di distinguere i diversi livelli di rating.

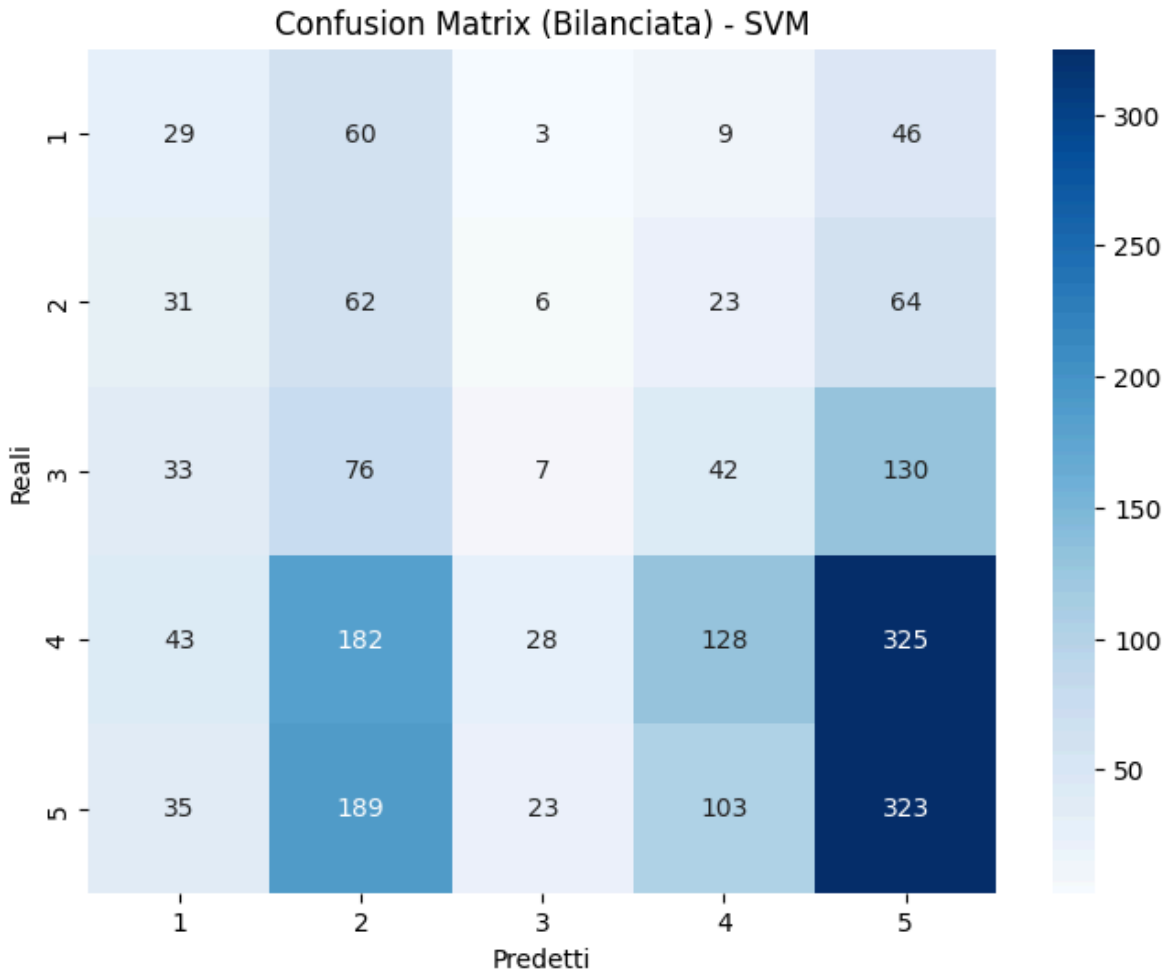

A differenza della confusion matrix precedente, dove le classi 1, 2 e 3 erano quasi invisibili, qui osserviamo una distribuzione del valori molto più omogenea:

- Classe 1: il modello identifica correttamente 29 istanze (rispetto alle sole 5 del modello precedente);
- Classe 2: le predizioni salgono a 62 (rispetto a 1).

Il bilanciamento ha costretto l'iperpiano di separazione a "dare importanza" anche ai feedback social associati a recensioni negative, che prima venivano totalmente ignorati a favore della classe maggioritaria.
Il modello sta "rischiando" di più, distribuendo i suoi tentativi su tutto lo spettro del rating.

5. Conclusioni

Il presente progetto ha analizzato la capacità predittiva delle interazioni social nel determinare il rating delle recensioni su Yelp.
L'intero percorso permette di sintetizzare i seguenti punti chiave:

- **Performance della Regressione Lineare:** la sua applicazione ha evidenziato l'inadeguatezza di un modello puramente lineare per questo problema. L'errore medio ottenuto indica uno scostamento medio di oltre una stella rispetto al valore reale. I test di **Feature Selection** hanno mostrato che la rimozione di variabili non peggiora drasticamente il modello, confermando che le tre variabili indipendenti trasportano informazioni quasi identiche.
- **L'efficacia della classificazione SVM:** il passaggio alla classificazione tramite SVM ha permesso di mappare il problema in modo più granulare, evidenziando le criticità legate alla distribuzione dei dati. Infatti, il modello base ha raggiunto un'accuratezza del 35,25%, ma l'analisi della confusion matrix ha rivelato che tale risultato era frutto di un forte bias verso la classe maggioritaria (4 stelle).
  L'introduzione del parametro **class_weight='balanced'** ha ridotto l'accuratezza globale al 27,45%**,** ma ha drasticamente migliorato la capacità del modello di identificare le classi minoritarie (1 e 2 stelle), passando da una quasi totale cecità a una distribuzione delle previsioni più equa.

L'ipotesi di ricerca iniziale, che prevedeva un legame matematico solido tra "successo social" e "rating", è stata parzialmente confutata. Sebbene esista una correlazione statistica, essa non è sufficiente a garantire una previsione affidabile. I feedback social risultano essere segnali non determinanti per il voto finale, il quale rimane influenzato prevalentemente da fattori non numeri, ad esempio contenuti nel testo della recensione.

6. Sviluppi futuri

L'analisi ha dimostrato che i soli metadati di interazione sociale non sono sufficienti per una classificazione accurata del rating. Tuttavia, questo "fallimento" predittivo apre la strada a diverse tecniche di ricerca che potrebbero incrementare drasticamente le performance del modello.
Com'è stato accennato, il limite principale riscontrato è l'assenza del contesto semantico. Lo sviluppo più naturale prevede l'analisi del linguaggio:

- **Sentiment Analysis**: l'estrazione della polarità emotiva dalle parole usate nelle recensioni permetterebbe di trasformare opinioni soggettive in dati numerici processabili;
- **Vettorizzazione del testo**: l'utilizzo di tecniche come TF-IDF (Term-Frequency-Inverse Document Frequency) o Word Embeddings permetterebbe di mappare il vocabolario degli utenti in uno spazio vettoriale, offrendo al modello SVM molte più dimensioni su cui lavorare;
- **Modelli Transformer**: l'adozione di architetture avanzate, come ad esempio BERT, consentirebbe di comprendere il sarcasmo e le sfumature di significato che i semplici conteggi di feedback non possono intercettare.

Per massimizzazione la capacità di generalizzazione, il modello potrebbe essere raffinato attraverso:

- **Grid Search:** una ricerca semantica dei parametri ottimali, come il fattore di regolarizzazione e il tipo di kernel (RBF, Polinomiale), per trovare il miglior equilibrio tra margine ed errore;
- **K-Fold Cross-Validation:** una tecnica di validazione incrociata per assicurarsi che l'accuratezza ottenuta sia stabile e non dipenda dallo specifico split dei dati effettuato;