*Progetti per il corso di Fondamenti di Scienza dei Dati*

*Docente: Domenico Garlisi*

*Email: domenico.garlisi@unipa.it*

## Modalità d'esame e Griglia di valutazione

**Scritto**
Prova della durata di 2h composta da 3 domande a risposta aperta ed un esercizio di implementazione di una piccola funzione in Python. Punteggio max 24 (6x4).

**Progetto**
Il punteggio massimo del progetto è di 6 punti, si valuterà l'applicazione delle tecniche richieste e le deduzioni ottenute dall'analisi dei dati. Verrà inoltre tenuto in conto il livello di autonomia nell'analisi e progettazione, individuazione di soluzioni originali oltre a quelle proposte dalla traccia di progetto.

**Istruzioni per l'Accesso e la Gestione dei Progetti di Gruppo**
I materiali relativi ai progetti (testi, dataset e file Excel con la composizione dei gruppi) sono disponibili su TEAMS nella cartella "GRUPPI-PROGETTI". A partire dal file Excel, occorre individuare per ciascun gruppo la lettera riportata nella prima colonna, che ne rappresenta l'identificativo. Questa lettera corrisponde al progetto assegnato al gruppo.
Una volta identificata la lettera, bisogna consultare il documento PDF contenente i testi dei progetti: ogni testo è associato a un dataset contrassegnato dalla stessa lettera. Vi invito a leggere attentamente le istruzioni riportate nel testo del progetto. In caso di dubbi, potete contattarmi via mail oppure fissare un ricevimento.
Da questo momento in poi, eventuali modifiche ai gruppi o alle assegnazioni devono essere concordate con me: per qualsiasi variazione, scrivetemi o contattatemi direttamente.

**Output progetto**:
- Relazione di progetto (circa 10 pagine) con la descrizione dell'analisi progettuale. Questa deve includere la descrizione delle features, l'intera pipeline di analysis, e risultati ottenuti. Il codice deve essere consegnato su file separati, la relazione può comunque riportare eventuali funzioni di rilievo per il progetto e le relative descrizioni.
- Codice sorgente del progetto (deve essere a parte alla relazione).

**Modalità di consegna dei progetti**:
- Invio e-mail all'indirizzo domenico.garlisi@unipa.it, si suggerisce di specificare nell'oggetto NOME_GRUPPO-ID-PROGETTO, es: MARIO-ROSSI-1 allegando:
    - PDF,WORD della relazione

- ZIP file contenente i codici sorgente in python.

## Progetto A

Dato il dataset che contiene diverse informazioni sui diverse regioni geografiche (stati), realizzare un progetto di data analysis che prevede la profilazione degli stati utilizzando le seguenti tecniche di clustering:

1. PCA (Principal Component Analysis)
2. Clustering K-Means
3. Clustering K-Neighbors

L'obbiettivo è verificare il numero di cluster che meglio rappresenta il dataset e associare ciascun elemento a uno di essi, quindi trovare le similitudini tra gli elementi appartenenti allo stesso gruppo. Applicare inoltre un metodo di StandardScalar ai dati prima delle tecniche di clustering. Utilizzare il metodo Elbow e Silhouette Score, per scegliere il numero corretto di cluster. Valutare la possibilità di selezionare un sott'insieme di features per applicare la cauterizzazione. In quest'ultimo caso, applicare la clusterizzazione sulle proiezioni delle due componenti principali. Nello scatter plot che visualizza i cluster, mostrare anche il centro di massa per ognuno dei cluster.
Il progetto deve mostrare eventuali correlazioni tra lo spazio delle features, in termini di grafici e matrice di correlazione. Oltre al plot con la proiezione dei dati nelle due componenti principali, mostrare Scree Plot e Biplot. (Nella standardizzazione di tipo scale ogni variabile di input si modifica sottraendo la media e dividendo per la deviazione standard per spostare la distribuzione in modo che abbia una media pari a zero e una deviazione standard pari a uno).
**Dataset**:
Country-data.csv

## Progetto B

Dato il dataset che contiene diversi sondaggi relativi ai clienti del famoso fast-food McDonalds, realizzare un progetto di data analysis che prevede la segmentazione dei clienti usando seguenti tecniche:

1. PCA (Principal Component Analysis)
2. Clustering K-Means
3. Clustering K-Neighbors

L'obbiettivo è verificare il numero di cluster che meglio rappresenta la soddisfazione dei clienti, quindi trovare le similitudini tra gli elementi appartenenti allo stesso gruppo.
Applicare inoltre un metodo di StandardScalar ai dati prima di eseguire il processamento. Utilizzare il metodo Elbow e Silhouette Score, per scegliere il numero corretto di cluster. Applicare la clusterizzazione sulle proiezioni sulle due componenti principali. Nello scatter plot che visualizza i cluster, mostrare anche il centro di massa per ognuno dei cluster. Verificare eventuali correlazioni tra i segmenti di clienti, l'età, il gradimento e la frequenza di visita.
Il progetto deve mostrare gli istogrammi con le frequenze di selezione su ogni features. Oltre al plot con la proiezione dei dati nelle due componenti principali, mostrare Scree Plot e Biplot. Nella standardizzazione di tipo scale ogni variabile di input si modifica sottraendo la media e

dividendo per la deviazione standard per spostare la distribuzione in modo che abbia una media pari a zero e una deviazione standard pari a uno.

**Features:**

0 yummy, 1 convenient, 2 spicy, 3 fattening, 4 greasy, 5 fast, 6 cheap, 7 tasty, 8 expensive, 9 healthy, 10 disgusting, 11 Like, 12 Age, 13 VisitFrequency, 14 Gender

**Dataset**:

mcdonalds.csv

## Progetto C

Dato il dataset che contiene informazioni su tutte le transazioni avvenute tra il 01/12/2010 e il 09/12/2011 per una specifica società di vendità online con sede nel Regno Unito. Realizzare uno studio di profilazione dei clienti in base all'RFM

R (Recency): Number of days since last purchase

F (Frequency): Number of transactions

M (Monetary): Total amount of transactions (revenue contributed)

Tale da progettare per l'azienda una campagna di pubblicità mirata.

Il dataset presenta le seguenti caratteristiche InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, CustomerID, Country. Da queste si dovranno estrarre le informazioni RMF, quindi un operazione di preprocessing dei dati, su cui fare la profilazione degli utenti utilizzando la tecniche di clustering K-Means. Verificare inoltre la presenza di outlier nei dati da clusterizzare. Applicare inoltre un metodo di StandardScalar ai dati prima delle tecniche di clustering. Utilizzare il metodo Elbow e Silhouette Score, per scegliere il numero corretto di cluster. Nello scatter plot che visualizza i cluster, mostrare anche il centro di massa per ognuno dei cluster.

Motivare la scelta dei cluster sulla base dei clienti per cui risulta più importante fare una notifica che invogli all'acquisto, per esempio attraverso una qualche promozione.

(Nella standardizzazione di tipo scale ogni variabile di input si modifica sottraendo la media e dividendo per la deviazione standard per spostare la distribuzione in modo che abbia una media pari a zero e una deviazione standard pari a uno).

**Dataset**:

OnlineRetail.csv.zip

## Progetto D

Dato il dataset che contiene le immagini di numeri scritti a mano (8x8=64 pixel), inseriti come righe del file csv (ultima colonna di ogni riga rappresenta il target/label). Il dataset può essere caricato anche da skleran con l'istruzione datasets.load_digits()

data, {ndarray, dataframe} of (1797, 64) shape: It is a data matrix.

target, {ndarray, series} of (1797,) shape: The target regarding classification.

(https://www.educative.io/answers/what-is-datasetsloaddigits-in-sklearn) l'esempio mostra anche la visualizzazione dell'immagine.

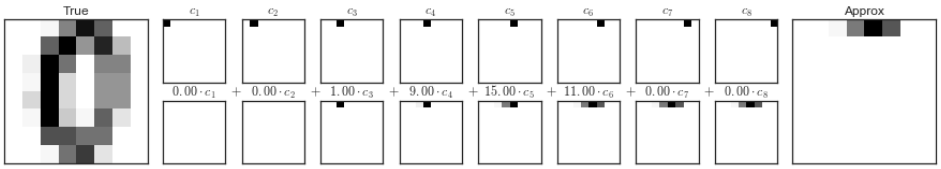


Realizzare un progetto di data analysis che prevede l'utilizzo della PCA per proiettare le 64 dimensioni sulle prime due componenti principali (questi punti sono la proiezione di ciascun punto dati lungo le direzioni con la varianza maggiore). Riprodurre la seguente immagine.

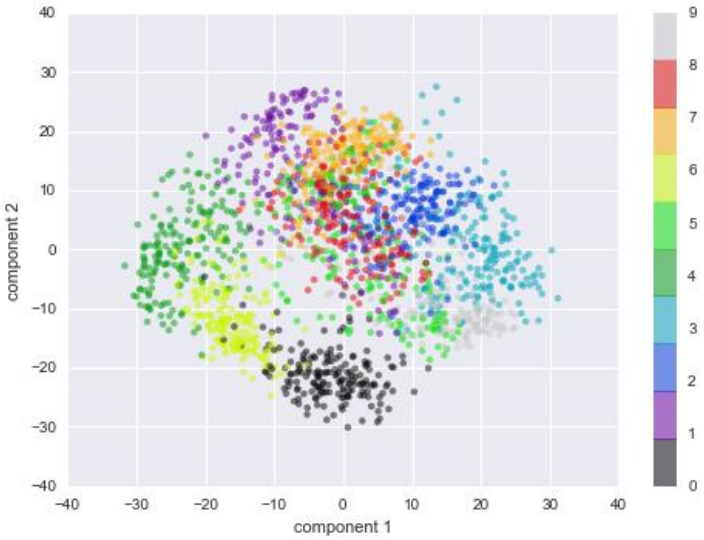


Realizzare un progetto di data analysis che prevede la clusterizzazione dei punti (k=10) tramite tecninca K-Means (basato sul centroide).
Ripetere la clusterizzazione sulle proiezioni sulle prime N componenti principali, con N che varia tra 2 e 6.
Per ogni clusterizzazione produrre una **matrice di confusione** che metta a confronto l'accuracy nella classificazione al variare del numero di componenti principali scelte.
**Dataset**:
digits.csv

## Progetto E

Dato il dataset che contiene le immagini di numeri scritti a mano (8x8=64 pixel), inseriti come righe del file csv. L'ultima colonna di ogni riga rappresenta il target. Il dataset può essere caricato anche da skleran con l'istruzione datasets.load_digits()

data, {ndarray, dataframe} of (1797, 64) shape: It is a data matrix.

target, {ndarray, series} of (1797,) shape: The target regarding classification.

([https://www.educative.io/answers/what-is-datasetsloaddigits-in-sklearn](https://www.educative.io/answers/what-is-datasetsloaddigits-in-sklearn)) l'esempio mostra anche la visualizzazione dell'immagine.

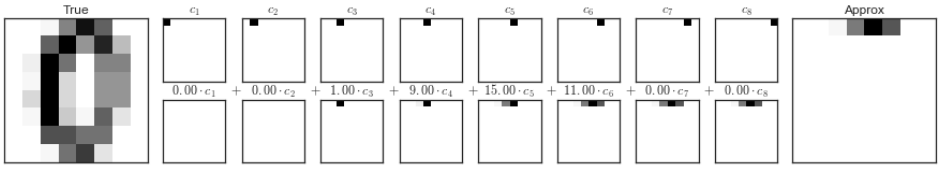

Realizzare un progetto di data analysis che prevede l'utilizzo della PCA per proiettare le 64 dimensioni sulle prime due componenti principali (questi punti sono la proiezione di ciascun punto dati lungo le direzioni con la varianza maggiore). Riprodurre la seguente immagine.

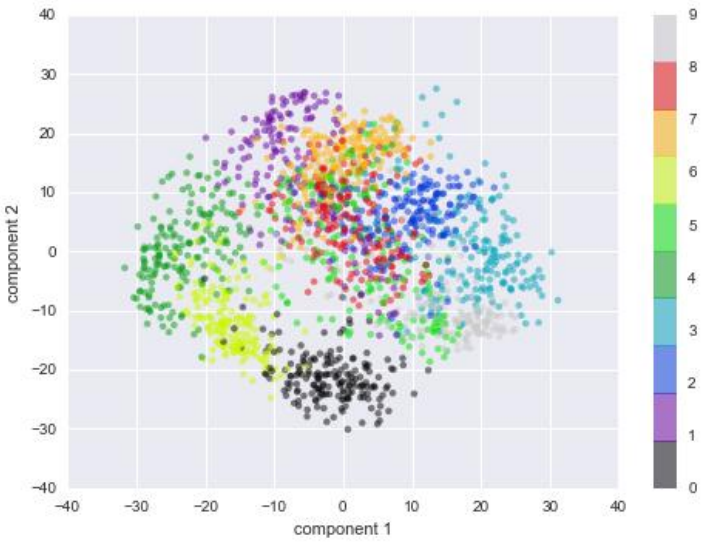


Classificare i punti della proiezione sulle prime due componenti principali tramite metodo SVM (Support Vector Machine). Utilizzare l'80% dei dati per la creazione del modello (traning) e il restante 20% per fare il test. Produrre una matrice di confusione che mostri l'accuracy della classificazione.

**Dataset**:

digits.csv

## Progetto F

Dato il dataset che contiene informazioni sulle trasmissione di una rete IoT, realizzare un progetto di data analysis che prevede la profilazione dei dispositivi utilizzando la tecninca di Clustering K-Means.

1. Per ogni dispositivo estrarre le seguenti features: chan, datr, lsnr, rssic, FCnt.
2. Evidenziare il numero di device e il numero di pacchetti per device.
3. Applicare un metodo di StandardScalar ai dati prima delle tecniche di clustering.
4. Si selezionino 5 dispositivi in modo random e si verifichi l'esistenza di una correlazione tra le features selezionate.
5. Raggruppare il dataset per dispositivo.
6. Associare a ogni dispositivo 5 nuove caratteristiche ottenute tramite media delle prime 4 features. Per l'ultima feature (FCnt) si estragga la differenza MAX-MIN.
7. Utilizzare le features selezionate per applicare la clusterizzazione di tipo k-means. Utilizzare il metodo Elbow e Silhouette Score, per scegliere il numero corretto di cluster.
8. Mostrare i cluster in un grafico 3D le cui dimensioni sono chan, datr, lsnr.

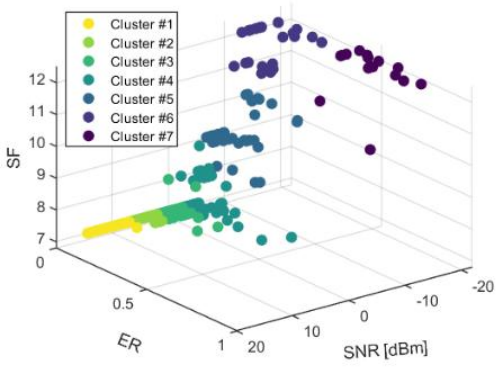


**Data analysis output**:
Nella standardizzazione di tipo scale ogni variabile di input si modifica sottraendo la media e dividendo per la deviazione standard per spostare la distribuzione in modo che abbia una media pari a zero e una deviazione standard pari a uno.
**Dataset**:
anonymized_radio_space_WM1_4.csv e anonymized_radio_space_WM1_5.csv → unire I due file in un unico dataset prima di eseguire lo studio.

## Progetto G

Dato il dataset che contiene l'evoluzione della simulazione della rete idrica in figura,

realizzare un progetto di data analysis che prevede la profilazione dei nodi della rete tramite le seguenti tecniche di clustering:

1. PCA (Principal Component Analysis)
2. Clustering K-Means

Il dataset contiene per ogni nodo (82 nodi in tutto) le misure orarie. Raggruppare le misure per nodo e mediare in modo da assegnare ad ogni nodo un'unica riga di misura da utilizzare per il raggruppamento.
Il progetto deve mostrare eventuali correlazioni tra lo spazio delle features, in termini di grafici e matrice di correlazione. Oltre al plot con la proiezione dei dati nelle due componenti principali, mostrare Scree Plot e Biplot.
Applicare inoltre un metodo di StandardScalar ai dati prima delle tecniche di clustering ( nella standardizzazione di tipo scale ogni variabile di input si modifica sottraendo la media e

dividendo per la deviazione standard per spostare la distribuzione in modo che abbia una media pari a zero e una deviazione standard pari a uno).
Utilizzare il metodo Elbow e Silhouette Score, per scegliere il numero corretto di cluster. Valutare la possibilità di selezionare un sott'insieme di features per applicare la cauterizzazione. Applicare la clusterizzazione (k-means) sulle proiezioni delle prime due componenti principali. Nello scatter plot che visualizza i cluster, mostrare anche il centro di massa per ognuno dei cluster.
**Dataset**:
1M_one_res_small_no_leaks_ordered_new_delimited_merged.csv

## Progetto H

Dato il dataset che contiene l'evoluzione della simulazione della rete idrica in figura (Il dataset contiene per ogni nodo, 82 nodi in tutto, le misure orarie),

Realizzare un progetto di data analysis per la previsione dei consumi ad una settimana. Si scelgano 5 nodi in modo casuale a cui applicare la predizione. Mostrare l'andamento delle richieste d'acqua (base_demand) nel tempo per ognuno dei nodi. Utilizzare un modello di regressione lineare per valutare la predizione dei consumi dei nodi. Valutate il modello dividendolo in training e testing set con le seguenti percentuali di set, 20%-80%, 50%-50%, 80%-20%, per ognuna di esse calcolare calcolando l'RMSE.
**Dataset**:
1M_one_res_small_no_leaks_ordered_new_delimited_merged.csv

## Progetto I

Dato il dataset che contiene informazioni sulle recensioni di attività dal sito yelp. Ogni osservazione in questo set di dati è una recensione di una particolare attività commerciale da parte di un particolare utente. La colonna "star" è il numero di stelle (da 1 a 5) assegnate dal recensore all'azienda. (In altre parole, è la valutazione dell'azienda da parte della persona che ha scritto la recensione. La colonna "cool" indica il numero di voti "cool" che la recensione ha ricevuto da altri utenti di Yelp. Tutte le recensioni iniziano con 0 voti "cool" e non c'è limite al numero di voti "cool" che una recensione può ricevere. In altre parole, si tratta di una

valutazione della recensione stessa, non dell'azienda. Le colonne "useful" e "funny"sono simili alla colonna "cool".
Acquisire i dati presenti nel file yelp.csv in un DataFrame. Esplorare la relazione tra ciascuno dei tipi di voto bello/utile/divertente) e il numero di stelle. Definire cool/useful/funny come caratteristiche e stars come risposta. Utilizzare un modello di regressione lineare per fare previsioni delle risposte. Valutate il modello dividendolo in training e testing set e calcolando l'RMSE. Provate a rimuovere alcune caratteristiche e vedete se l'RMSE migliora.
Invece di trattare questo problema come un problema di regressione, trattatelo come un problema di classificazione e vedete quale accuratezza di test potete ottenere con SVM.
**Dataset**:
yelp.json è il formato originale del file. yelp.csv contiene gli stessi dati, in un formato più comodo.

## Progetto L

Dato il dataset che contiene informazioni sui noleggi di un bikesharing. Analizzare i dati in termini osservazioni e features. Visualizzazione il numero di noleggi in funzione della temperatura, dell'umidità e della stagione. Verificare tramite matrice di correlazione le features più appropriate per predire il numero di noleggi in funzione della temperatura. Costruire un modello di regressione lineare. Utilizzare il modello per la previsione dei noleggi sull'ultima parte del dataset, e.g. 20%. Lavorare con più caratteristiche aggiungendole man mano. Confrontare il risultato del modelli al variare della divisione tra training e test. Fare il confronto tramite RMSE.
**Dataset**:
bikeshare.csv

## Progetto M

Dato il dataset che contiene informazioni sulle dimensioni e sui tipi di IRIS e la libreria sci-kit-learn, realizzare un modello di classificazione che sfrutta la tecnica SVM (support vector machine). I dati sull'iris consistevano in 150 campioni di tre specie di Iris. La prima colonna rappresentava la lunghezza del sepalo, la seconda la larghezza del sepalo, la terza la lunghezza del petalo e la quarta la larghezza del petalo. Realizzare uno scatterplot per capire come vengono distribuiti i dati. Variare le caratteristiche da utilizzare per fare la classificazione delle osservazioni e mostrarne l'impatto sulle performance. Mostrare l'accuratezza del classificatore SVM utilizzando diversi tipi di kernel, kernel polinomiale e RBF. Tracciare il confine decisionale dell'SVM sul diagramma. Se servisse, fare una riduzione utilizzando PCA.

**Dataset**:
IRIS.csv

## Progetto N

Dato il dataset che contiene i volti di diversi personaggi noti. Realizzare uno scatterplot a due dimensioni che mostra la proiezione dei volti nelle prime due componenti principali. Per il

sottogruppo di personaggi Ariel Sharon, Colin Powell, Donald Rumsfeld, George W Bush, Gerhard Schroeder, Hugo Chavez, Tony Blair,

la riga superiore mostra le immagini di input, mentre la riga inferiore mostra la ricostruzione delle immagini da appena 150 delle ~3.000 caratteristiche principali.
Il progetto deve utilizzare poi le prime 150 componenti principali ed eseguire su questi la classificazione tramite SVM. Quindi mostrare l'accuratezza del classificatore SVM utilizzando il kernel RBF.
**Dataset**:
lfw-funneled.tgz

## Progetto O

Dato il dataset che contiene le caratteristiche relative alle case di **Boston**. Realizzare uno studio di correlazioni tra le diverse features e scegliere un adeguato sottogruppo di features per applicare un modello di **regressione lineare** per prevedere i prezzi delle abitazioni che utilizzi le due tecniche LASSO e RIDGE e confrontarne i risultati in termini di MSE e MAE.

**Dataset**:
boston.csv

## Progetto P

Dato il dataset che contiene le caratteristiche relative alle case di **Boston**. Realizzare uno studio di correlazioni tra le diverse features e scegliere un adeguato sottogruppo di features (anche una sola) per applicare un modello di **regressione non lineare** che prevede i prezzi delle abitazioni. Si estragga il modello dal primo 50% (training) dei dati e si testi la sua applicazione in termini di errore nella seconda parte (secondo 50% - test). Si faccia riferimento al codice presente a questo link: https://github.com/dynamicslab/databook_python/blob/master/CH04/CH04_SEC05_1_CrossValidate.ipynb

**Dataset**:
boston.csv

## Progetto Q

Dato il dataset che contiene le informazioni sulle statistiche dei giocatori NBA. Realizzare uno studio di correlazioni tra le diverse features e scegliere 2 features per applicare un modello di

**regressione lineare** e **non lineare** che a partire da una caratteristica ne prevede un'altra (si ha piena libertà in termini di scelta delle caratteristiche). Si estragga il modello dal primo 50% (training) dei dati e si testi la sua applicazione in termini di errore nella seconda parte (secondo 50% - test).

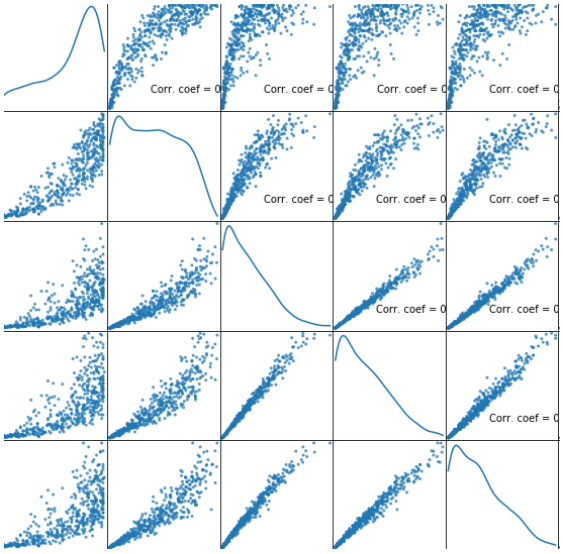


**Dataset**:
players_stats.csv